

首先是任务定义。风格迁移任务要求我们给一张图片作为参考，并提供有关内容的文本提示词，生成一张风格与参考图片一致，内容和文本提示词一致的图片。

针对这个任务，现有的定制方法有的通过匹配内容或者视觉特征的统计分布，基于深度学习的一些方法，比如 DreamBooth，则通过LoRA微调的方式为模型注入生成特定风格的能力。虽然效果较好，但有着需要训练时间、计算资源，且需要针对每个风格单独训练的问题。我们想要尝试的问题就是，是否可以训练一个统一的网络，从一张图片提取它的风格，并使模型能够具有生成这个风格图片的能力

在语言模型领域，如何实现长上下文推理是一个重要问题。上下文蕴含着知识、语言风格等信息，而风格参考图片同样蕴含着色调、材质、光照、抽象等信息。可以说，参考图片是图像生成模型的视觉上下文。

在压缩存储上下文，或者说扩展上下文方面，有两篇工作启发了我们。其中与视觉相关的是HyperDreamBooth，它认为视觉信息可以被直接转化为参数空间的参数调整。SHINE则说明了，在语言模型领域，参数端的微调可以扩展模型可用的上下文边界。而它们实现将上下文转换为参数端的方式基本都是HyperNetwork

HyperNetwork不直接完成生成任务，而是为其他的网络生成参数。训练好的HyperNetwork只需要一次前传生成模型参数，就可以直接应用到另一个训练好的网络上。对于一个网络来说，直接预测参数有困难，预测LoRA中的AB低秩矩阵可能也并非容易，所以很多HyperNetwork会选择引入两个辅助矩阵，降低HyperNetwork需要预测的参数量，就如PPT中的两个aux辅助矩阵所示。

所以 HyperDreamBooth 中采用了 Lightweight DreamBooth，也就是 LiDB 的设计。

它并不是直接生成完整 LoRA 矩阵，而是先固定两个辅助矩阵，构成一个较小的 LoRA 参数子空间。HyperNetwork 只需要根据输入的人脸图片，预测这个子空间里的系数矩阵。这样做的好处是，一方面大幅减少了 HyperNetwork 需要输出的参数量，另一方面也让生成出来的参数仍然保持 LoRA 的结构，可以比较稳定地注入到扩散模型中。HyperDreamBooth 进一步用生成的 LiDB 参数作为初始化，再做很短时间的 rank-relaxed finetuning，从而提升个性化细节。

受到这个思路启发，我们把输入从人脸身份图片换成风格参考图片，也就是 Image2LoRA 的核心想法。我们的假设是：一张风格图像中包含足够的风格上下文信息，例如色调、纹理、材质、光照和笔触模式，因此可以通过一个 HyperNetwork 把这些信息转换为 LoRA 参数，使一个冻结的文本到图像生成模型具备对应风格的生成能力。

具体结构上，我们首先使用 DINOv2 作为图像编码器，提取参考图片的 patch-level visual tokens。然后把这些视觉 token 输入到一个 transformer decoder 结构的 HyperNetwork 中。这个 HyperNetwork 不直接生成图片，而是为 Stable Diffusion 1.5 的 UNet 中若干 attention linear layers 生成 LightLoRA 权重。生成出的 LoRA 权重会在推理时动态注入到冻结的 SD1.5 UNet 中。文本提示词仍然控制图像内容，而参考图片生成的 LoRA 参数控制图像风格。

在我们的实现中，同样没有让 HyperNetwork 直接生成完整的 LoRA A、B 矩阵，而是采用辅助矩阵的方式。对于每一层，HyperNetwork 只生成一个很小的 embedding，然后把它拆成 down-side 和 up-side 的系数。再通过训练得到的 down_aux 和 up_aux 辅助矩阵，组合出最终的 LoRA A 和 B。当前设置中，rank 等于 1，down dimension 是 64，up dimension 是 32，因此每一层只需要生成 96 个标量。这样整个 LightLoRA 大约只有几十 KB，能够比较轻量地表示一个参考图像对应的风格调制。

训练时，我们采用标准的扩散模型噪声预测目标。每个训练样本包含参考风格图像、目标风格图像和文本描述。训练流程是：先编码参考图像，生成动态 LoRA；再把目标图像加噪到 latent space；最后让注入了动态 LoRA 的 UNet 预测噪声。训练过程中，Stable Diffusion 1.5 的主体、VAE、文本编码器和图像编码器基本保持冻结，主要训练 HyperNetwork 和 LightLoRA 的辅助矩阵。也就是说，我们并不是重新训练一个生成模型，而是在学习如何把参考图像转换为模型侧的风格参数，并保留生成模型本身的开放生成能力。

为了快速验证方法有效性，我们目前选择了 Stable Diffusion 1.5 作为基础模型，因为它规模相对较小、训练和验证成本较低。训练数据来自 OmniStyle-150k，我们使用了其中大约 100 种风格、1.4 万到 1.5 万张图片。每个样本包含一张风格参考图、目标图以及 caption。实验中，我们主要和不使用 LoRA 的 SD1.5 baseline 进行对比，也就是在同样文本提示词下，看 Image2LoRA 是否能够引入参考图像中的风格信息。

从目前的定性结果来看，Image2LoRA 相比 baseline 能够更明显地迁移参考图中的色调、纹理和绘画感。例如在山景和宫殿这两个例子中，baseline 更多只是按照文本提示生成常规图像，而 Image2LoRA 的输出在整体颜色、材质质感和艺术化程度上更接近参考图。这说明参考图像中的信息确实通过动态 LoRA 改变了生成分布，而不是只依赖文本提示词。

当然，目前结果还只是初步验证。我们后续还需要做更系统的量化实验。可能的指标包括：用 CLIP 或 DINO 特征相似度衡量风格相似性，用 CLIPScore 或 VQA-based score 衡量文本一致性，用 FID、KID 或 aesthetic score 衡量图像质量，也可以进一步做人类偏好实验。因为风格迁移本身很难只用单一指标评价，所以我们倾向于同时报告风格一致性、文本对齐和图像质量。

未来工作主要有几个方向。第一，可以像 HyperDreamBooth 一样，在生成 LoRA 之后加入 rank-relaxed finetuning，进一步提升单个参考风格的质量。第二，可以把基础模型从 SD1.5 扩展到 SDXL 或者 transformer-based diffusion models，验证方法在更强 backbone 上的效果。第三，需要系统研究 HyperNetwork 的结构、LoRA rank、注入层范围等因素。最后，也需要评估通用性和单风格质量之间的 trade-off：统一 HyperNetwork

更通用，但它是否会牺牲某些单一风格上的上限，这是后续实验需要回答的问题。

总结来说，我们尝试把风格参考图像看作图像生成模型的视觉上下文，并通过 HyperNetwork 将这种上下文转换为动态 LightLoRA 参数。这样可以避免每个风格单独训练一套 LoRA，同时保留扩散模型本身的文本生成能力。当前初步结果说明，这条路线是可行的，也为后续更大规模、更系统的风格生成实验提供了基础。